¿Qué distingue a un paciente de alto riesgo?

Análisis multivariado de los registros de monitoreo clínico del Hospital 4

Informe estadístico — Fase I (versión corregida)

Exploración de Datos Multivariados
Grupo 4 — Jacob, Barzola, Henchoz
Octubre de 2026

Resumen

Este informe analiza 13.331 registros de monitoreo clínico del Hospital 4 con el propósito de establecer qué información, entre la que la institución recolecta en cada control, permite efectivamente distinguir a los pacientes de alto riesgo de los de bajo riesgo.

De las dieciocho variables cuantitativas registradas, sólo cinco separan los dos grupos: triglicéridos, colesterol, frecuencia cardíaca, creatinina e índice de masa corporal. Las trece restantes presentan diferencias despreciables; el caso extremo es la presión arterial sistólica, cuya media es idéntica en ambos grupos (124,49 mmHg). Ninguna de las diez variables categóricas —sexo, diagnóstico, hábito tabáquico, actividad física, región, nivel socioeconómico, ocupación, turno, estación y grupo etario— se asocia con la clasificación: el porcentaje de alto riesgo se mantiene entre 51,21 % y 53,70 % en todas sus categorías, frente al 52,60 % de la base completa.

Vistas en conjunto, las cinco variables separan los grupos con más claridad que cualquiera de ellas por separado. La distancia de Mahalanobis entre los centros de ambos grupos es de 2,218 desvíos, contra 0,183 para las trece variables restantes, y la prueba T^2 de Hotelling rechaza la igualdad de los vectores de medias ($F(5; 13.325) = 3.269$; $p < 0,001$). Los gráficos multivariados muestran que la diferencia no es sólo de nivel sino de forma.

Las cinco variables se reducen a dos dimensiones independientes que explican el 60,2 % de su variabilidad conjunta: un eje lipídico-adiposo, que concentra triglicéridos, colesterol e índice de masa corporal, y un eje cardio-renal, que reúne frecuencia cardíaca y creatinina. El primero separa los grupos con una magnitud de efecto de 1,558. Un análisis de componentes principales sobre catorce variables, sin selección previa, encuentra el mismo eje y separa los grupos con 1,469: la selección no fabrica el resultado.

El grupo de alto riesgo es internamente heterogéneo. En índice de masa corporal su dispersión es 2,64 veces mayor y presenta dos modas: 2.215 pacientes con bajo peso y 2.921 con obesidad conviven bajo una misma etiqueta. Dentro del alto riesgo se distinguen tres perfiles —bajo peso, índice entre 18,5 y 30 con frecuencia cardíaca elevada, y obesidad con lípidos muy altos— que comparten una creatinina de 1,43 a 1,44 mg/dL. Esto sustenta la hipótesis, que la segunda fase deberá contrastar, de que la categoría de alto riesgo agrupa perfiles clínicamente distintos.

Contenido

1. Introducción
    1.1. Estado inicial de los datos
    1.2. Base final de trabajo
2. La población atendida
    2.1. Comportamiento de las variables cuantitativas
    2.2. Las variables derivadas construidas
3. Pregunta de investigación y enfoque
    3.1. Criterios metodológicos adoptados
4. Qué separa a los dos grupos de riesgo
    4.1. Contraste formal de las diferencias
    4.2. Lectura clínica de las cinco variables
5. Las cinco variables en conjunto: visualización multivariada y contraste de medias
    5.1. Dispersión tridimensional
    5.2. Coordenadas paralelas, perfiles multivariados y gráfico radial
    5.3. Contraste multivariado de medias
6. Qué no separa a los dos grupos de riesgo
    6.1. Variables categóricas: tablas de contingencia
    6.2. El caso de la glucosa: riesgo y diagnóstico son dimensiones distintas
7. Estructura conjunta de las variables discriminantes
    7.1. Covarianza y correlación
    7.2. Observaciones atípicas multivariadas
    7.3. Reducción a componentes principales
    7.4. Los grupos de riesgo en el plano factorial
    7.5. Resultado de control: catorce variables sin selección previa
8. El grupo de alto riesgo no es homogéneo
    8.1. Dispersión comparada y distribución del índice de masa corporal
    8.2. Tres perfiles bajo una misma etiqueta
9. Conclusiones y líneas de trabajo futuras
    9.1. Un núcleo de cinco variables
    9.2. Limitaciones del análisis
    9.3. Líneas de trabajo futuras
    9.4. Recomendaciones para el registro de datos
Anexo. Ficha técnica de la base analizada

1. Introducción

El presente informe analiza los registros de monitoreo clínico del Hospital 4 con el objetivo de identificar qué información, entre toda la que la institución recolecta en cada control, resulta efectivamente útil para distinguir a los pacientes según su nivel de riesgo. El trabajo se enmarca en una primera fase de exploración descriptiva y multivariada; una segunda fase abordará la construcción de una tipología de pacientes.

La base de datos entregada reúne observaciones individuales de pacientes registradas mediante sistemas de monitoreo continuo y registros administrativos. Cada fila corresponde a la observación de un paciente en un momento determinado e incluye signos vitales, variables antropométricas, biomarcadores metabólicos, información sociodemográfica, variables clínicas categóricas e indicadores derivados de riesgo. En su versión original la base contenía 15.345 registros y 34 variables.

1.1. Estado inicial de los datos

La revisión inicial reveló que la base no podía analizarse en el estado en que fue entregada. Se detectaron seis clases de problemas de calidad, todos ellos documentados y tratados antes de cualquier análisis.

Variables sin contenido informativo. Una de las columnas presentaba un 96,75 % de valores faltantes: sólo 498 de los 15.345 registros tenían algún dato. Otra registraba de manera constante el nombre de la institución, de modo que su varianza es nula. Una tercera correspondía a una marca auxiliar de control y no constituye una variable clínica. Las tres fueron eliminadas.

Registros duplicados. Se identificaron 10 registros exactamente repetidos, es decir, filas idénticas en la totalidad de sus campos. Al no existir ningún elemento que permita interpretarlos como dos controles distintos del mismo paciente, se los consideró un error de carga y se conservó una sola copia de cada uno.

Códigos centinela de error. Las variables de sexo, de categoría de riesgo y la marca temporal del registro contenían, además de sus valores legítimos, códigos con el formato ERROR_nnn, que no representan categorías reales sino marcas dejadas por el sistema de carga ante un dato inválido. Se contabilizaron 1.452 apariciones —487 en sexo, 486 en categoría de riesgo y 479 en la marca temporal —, que fueron reconvertidas a valores faltantes. Un código de error almacenado en el mismo campo que el dato válido es indistinguible de una categoría genuina para cualquier procesamiento automático, y puede propagarse silenciosamente a los reportes.

Inconsistencias de escritura. Las variables categóricas presentaban la misma categoría escrita de múltiples formas: diferencias de mayúsculas y minúsculas, espacios sobrantes, separadores distintos y errores de tipeo. El nivel de actividad física, por ejemplo, aparecía como «Low», «LOW», «LoW», « low » y «lwo»; la ocupación incluía «retird» por «retired» y la región alternaba entre «Semi-Urban», «Semiurban» y «semi urban». Todas las categorías fueron normalizadas y traducidas al español.

Valores faltantes. Se adoptó un criterio diferenciado según el rol de cada variable. Los faltantes de las variables de contexto —tipo de medicación, nivel de actividad física, región y ocupación— se conservaron, porque su ausencia es de naturaleza administrativa y no impide analizar el estado clínico del paciente. En cambio se descartaron los registros con siete o más campos ausentes, que no reúnen información suficiente para caracterizar al paciente: 2.002 registros, el 13,0 % de la base original. Luego se eliminaron 9 duplicados (el décimo ya había sido descartado por el criterio anterior), el control de rangos fisiológicos eliminó dos registros cuya frecuencia cardíaca era desconocida, y una validación final descartó un registro que carecía a la vez de identificación, de sexo y de etiqueta de riesgo. En total se descartaron 2.014 registros.

Precisión espuria. Las variables numéricas venían expresadas con hasta dieciséis decimales, una precisión que ningún instrumento clínico posee. Se las redondeó a dos decimales.

1.2. Base final de trabajo

Tras la depuración, la base de análisis quedó conformada por 13.331 registros y 31 variables, correspondientes a 13.331 pacientes distintos. Se incorporaron además cinco variables derivadas: un conteo de datos faltantes por registro, un indicador de anemia construido sobre los umbrales de hemoglobina diferenciados por sexo, un indicador de taquicardia, una categorización de la función renal según creatinina sérica y un indicador de colesterol total elevado.

Los valores faltantes remanentes se concentran en las cuatro variables de contexto: tipo de medicación (30,68 %), nivel de actividad física (18,06 %), región (4,18 %) y ocupación (3,26 %). Ninguna variable clínica ni ningún signo vital presenta datos faltantes. Se verificó que esa ausencia no se concentra en ningún tipo particular de paciente: el porcentaje de alto riesgo es 52,83 % entre los registros completos y 52,34 % entre los incompletos, y las proporciones de cada diagnóstico y nivel socioeconómico también coinciden.

2. La población atendida

Perfil demográfico. La edad media de los pacientes es de 53,53 años, con una mediana de 53 y un desvío estándar de 20,66. El rango va de 18 a 89 años y la distribución es prácticamente uniforme a lo largo de ese intervalo. La composición por sexo está equilibrada: 6.666 pacientes de sexo masculino y 6.665 de sexo femenino.

Perfil clínico. El diagnóstico más frecuente es la ausencia de patología: 4.698 pacientes (35,24 %) figuran como sanos. Le siguen la hipertensión, con 3.289 (24,67 %), la diabetes, con 2.487 (18,66 %), la enfermedad pulmonar obstructiva crónica, con 1.557 (11,68 %), y la enfermedad cardíaca, con 1.300 (9,75 %). La categoría de riesgo divide a la población casi por mitades: 7.012 pacientes (52,60 %) de alto riesgo y 6.319 (47,40 %) de bajo riesgo.

Perfil sociodemográfico. El 42,18 % de los pacientes reside en zona urbana, el 31,96 % en zona semiurbana y el 25,87 % en zona rural. El 45,19 % pertenece al nivel socioeconómico medio, el 39,68 % al bajo y el 15,13 % al alto.

2.1. Comportamiento de las variables cuantitativas

La Tabla 1 resume las dieciocho variables cuantitativas que el hospital registra en cada control, ordenadas por coeficiente de variación, que expresa la dispersión en relación con la media y permite comparar variables medidas en escalas distintas.

Tabla 1. Medidas de resumen de las dieciocho variables cuantitativas, ordenadas por coeficiente de variación (n = 13.331).

Variable	Media	Mediana	Desvío	Mínimo	Máximo	CV (%)
Temperatura corporal	36,75	36,75	0,44	36,00	37,50	1,19
Saturación de oxígeno	97,49	97,52	1,54	70,11	100,00	1,58
Presión arterial media	94,48	94,33	4,85	83,33	105,67	5,13
Presión sistólica	124,49	124,00	8,74	110,00	188,00	7,02
Presión diastólica	79,51	79,00	5,83	70,00	117,00	7,33
Altura	1,75	1,75	0,14	1,50	2,00	8,24
Hemoglobina	14,18	14,30	1,68	7,70	20,90	11,83
Frecuencia cardíaca	79,53	80,00	11,64	39,00	167,00	14,64
Frecuencia respiratoria	15,51	16,00	2,36	12,00	43,00	15,22
Peso	75,00	74,99	14,51	50,01	99,99	19,34
Colesterol	213,06	209,80	41,33	91,60	373,70	19,40
Presión de pulso	44,97	45,00	10,35	21,00	69,00	23,00
Índice de masa corporal	24,96	24,31	6,41	12,59	44,19	25,69

Variable	Media	Mediana	Desvío	Mínimo	Máximo	CV (%)
Variabilidad de frec. cardíaca	0,10	0,10	0,03	0,05	0,43	29,55
Glucosa	114,79	104,20	37,18	43,50	381,23	32,39
Triglicéridos	198,69	186,60	71,80	40,20	546,10	36,14
Edad	53,53	53,00	20,66	18,00	89,00	38,60
Creatinina	1,27	1,21	0,50	0,40	7,32	39,54

Las variables se ordenan en dos bloques muy distintos. La temperatura corporal y la saturación de oxígeno apenas varían entre pacientes (coeficientes de variación de 1,19 % y 1,58 %): una variable que no varía no puede explicar diferencias entre individuos. En el otro extremo, la creatinina, los triglicéridos y la glucosa superan el 30 % y son las candidatas naturales a contener información discriminante. La glucosa presenta una media de 114,79 mg/dL frente a una mediana de 104,20 mg/dL, lo que revela una cola derecha correspondiente a los pacientes diabéticos; los triglicéridos muestran el mismo patrón y la creatinina llega a 7,32 mg/dL, lo que señala un subgrupo con compromiso renal severo.

El criterio del rango intercuartílico identificó valores atípicos univariados en 1.711 casos de glucosa, 301 de creatinina, 106 de colesterol, 104 de triglicéridos, 33 de índice de masa corporal y 9 de frecuencia cardíaca; sólo 14 pacientes presentan saturación inferior a 90 %. Ninguno fue eliminado: todos se sitúan dentro de rangos fisiológicamente posibles y corresponden a casos clínicos extremos reales, no a errores de carga.

2.2. Las variables derivadas construidas

Conteo de datos faltantes. Cuántos campos de cada paciente quedaron sin dato. En la base final el 52,8 % de los registros está completo y ninguno tiene más de tres campos vacíos. **Indicador de anemia.** Hemoglobina por debajo de 13,0 g/dL en varones y 12,0 g/dL en mujeres. **Indicador de taquicardia.** Frecuencia cardíaca de 100 latidos por minuto o más: sólo 7 pacientes (0,05 %). **Categoría de creatinina.** Normal por debajo de 1,00 mg/dL, alteración leve entre 1,00 y 1,49, moderada entre 1,50 y 2,99 y severa desde 3,00; el 21,5 % de los pacientes está en los dos niveles superiores. **Colesterol elevado.** Colesterol total de 240 mg/dL o más: el 24,5 % de la población.

Estas variables cumplen una función descriptiva. En el análisis multivariado se trabajó con las variables continuas originales, para no perder información al discretizar.

3. Pregunta de investigación y enfoque

El hospital clasifica a cada paciente en una de dos categorías de riesgo y registra, para llegar a esa clasificación o en paralelo a ella, dieciocho variables cuantitativas y una decena de variables categóricas. Este informe se pregunta:

> *¿Qué distingue a un paciente clasificado como de alto riesgo de uno de bajo riesgo en el Hospital 4, y cuánta de la información que la institución registra en cada control es realmente necesaria para establecer esa distinción?*

La pregunta tiene dos filos. El primero es descriptivo: identificar qué variables separan efectivamente a los dos grupos. El segundo es práctico: si sólo una parte de lo que se registra contribuye a la distinción, el resto representa un esfuerzo de registro cuyo rendimiento conviene revisar.

El abordaje consta de seis etapas: comparar cada variable entre los grupos; representar y contrastar en conjunto las que resulten discriminantes; examinar las variables categóricas mediante tablas de contingencia; estudiar la estructura conjunta mediante covarianzas, correlaciones y distancias; reducirla a componentes principales; y comparar la dispersión interna de cada grupo. Las variables mencionadas en las guías de la asignatura se tomaron como referencia y no como prescripción: el

recorte de este informe surge de un criterio explícito y verificable sobre los datos —la capacidad de cada variable para separar los grupos de riesgo—.

3.1. Criterios metodológicos adoptados

El criterio de relevancia es la magnitud del efecto, no la significación. Con 13.331 registros prácticamente cualquier diferencia alcanza significación estadística: la altura difiere entre grupos con $p < 0{,}001$ y la diferencia es de dos centímetros. La selección de variables se basó por eso en la magnitud del efecto d, que expresa la diferencia de medias en desvíos estándar y no depende del tamaño de muestra, con el umbral convencional de 0,20.

Las pruebas se eligen según sus supuestos. La homogeneidad de varianzas se evaluó con la prueba de Levene. Como la rechaza en las variables discriminantes, las medias de dos grupos se compararon con la prueba t de Welch, que no supone varianzas iguales, y se verificaron con la prueba de Wilcoxon-Mann-Whitney. Para tres grupos con varianzas distintas se usó la prueba de Kruskal-Wallis, y para el vector de medias, la T^2 de Hotelling.

El análisis multivariado se realiza sobre variables estandarizadas. Las varianzas de las variables difieren en cuatro órdenes de magnitud; trabajar sobre covarianzas equivaldría a ponderar cada variable por el tamaño de sus unidades. La estandarización (media 0, desvío 1) y la matriz de correlación ponen a todas en igualdad de condiciones.

Los valores atípicos se conservan y el número de componentes se decide por dos criterios. Ningún valor extremo fue eliminado, porque todos son fisiológicamente posibles. En el análisis de componentes se retuvieron los autovalores mayores que uno (criterio de Kaiser), verificando que coincidieran con el codo del gráfico de sedimentación.

4. Qué separa a los dos grupos de riesgo

Para cada una de las dieciocho variables cuantitativas se calcularon la media y el desvío en cada grupo de riesgo, la magnitud del efecto d y los contrastes formales (Tabla 2). Por convención, $|d|$ inferior a 0,20 es una diferencia despreciable; alrededor de 0,50, moderada; y superior a 0,80, grande.

Tabla 2. Comparación de las dieciocho variables entre grupos de riesgo, ordenadas por magnitud del efecto. t y p: prueba de Welch; última columna: prueba de Levene. En sombreado, las variables discriminantes (n = 7.012 alto riesgo; 6.319 bajo riesgo).

Variable	Media alto	Desvío alto	Media bajo	Desvío bajo	d	t	p	p Levene
Triglicéridos	**237,95**	**66,20**	**155,12**	**49,03**	**1,411**	**82,61**	**< 0,001**	**< 0,001**
Colesterol	**233,80**	**39,02**	**190,03**	**30,13**	**1,248**	**72,88**	**< 0,001**	**< 0,001**
Frecuencia cardíaca	**83,63**	**12,23**	**74,99**	**8,98**	**0,798**	**46,75**	**< 0,001**	**< 0,001**
Creatinina	**1,43**	**0,45**	**1,10**	**0,50**	**0,699**	**40,08**	**< 0,001**	**0,008**
Índice de masa corporal	**25,84**	**8,24**	**24,00**	**3,12**	**0,290**	**17,38**	**< 0,001**	**< 0,001**
Altura	1,74	0,15	1,76	0,13	−0,176	−10,19	< 0,001	< 0,001
Peso	75,24	15,92	74,74	12,75	0,034	1,99	0,046	< 0,001
Frecuencia respiratoria	15,54	2,39	15,49	2,33	0,021	1,21	0,227	0,871
Edad	53,72	20,59	53,33	20,74	0,019	1,08	0,280	0,466
Variabilidad de frec. cardíaca	0,10	0,03	0,10	0,03	−0,014	−0,83	0,408	0,961
Presión diastólica	79,54	5,84	79,47	5,81	0,011	0,65	0,513	0,999
Temperatura corporal	36,74	0,44	36,75	0,43	−0,007	−0,42	0,674	0,396
Presión de pulso	44,94	10,38	45,02	10,31	−0,007	−0,43	0,669	0,743
Presión arterial media	94,50	4,82	94,47	4,87	0,006	0,32	0,749	0,139

Variable	Media alto	Desvío alto	Media bajo	Desvío bajo	d	t	p	p Levene
Glucosa	114,71	37,15	114,87	37,21	−0,004	−0,24	0,809	0,839
Saturación de oxígeno	97,49	1,57	97,49	1,51	−0,002	−0,09	0,927	0,493
Hemoglobina	14,18	1,70	14,18	1,66	−0,002	−0,11	0,914	0,361
Presión sistólica	124,49	8,77	124,49	8,70	0,000	0,01	0,992	0,843

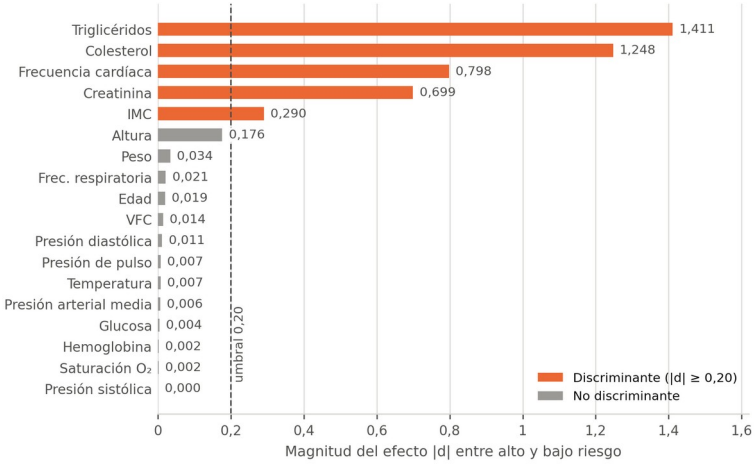


Figura 1. Magnitud del efecto entre grupos de riesgo para las dieciocho variables cuantitativas. Sólo cinco superan el umbral de relevancia de 0,20.

De las dieciocho variables, sólo cinco separan a los grupos: triglicéridos, colesterol, frecuencia cardíaca, creatinina e índice de masa corporal. Las trece restantes presentan magnitudes de efecto entre −0,176 y 0,034; el caso extremo es la presión sistólica, con 124,49 mmHg en ambos grupos. El corte no depende del umbral elegido: cualquier valor entre 0,176 y 0,290 selecciona las mismas cinco variables, porque entre la quinta (índice de masa corporal, 0,290) y la sexta (altura, 0,176) hay un salto, y entre la sexta y la séptima (peso, 0,034) la magnitud cae a menos de la quinta parte. Tampoco depende de suponer varianzas iguales: recalculada con la varianza promedio de los dos grupos, la d da 1,422, 1,256, 0,805, 0,697 y 0,296, con el mismo orden.

4.1. Contraste formal de las diferencias

La prueba de Levene rechaza la homogeneidad de varianzas en las cinco variables discriminantes y también en el peso y la altura, y no la rechaza en ninguna de las once restantes. Por eso las medias se compararon con la prueba t de Welch. Las cinco discriminantes alcanzan valores de t entre 17,38 y 82,61, todas con $p < 0,001$. La altura también resulta significativa ($t = -10,19$), y el peso apenas ($t = 1,99$; $p = 0,046$) pese a una diferencia de medio kilo (75,24 contra 74,74 kg; $d = 0,034$): son los ejemplos más claros de que, con esta muestra, significativo no quiere decir relevante. Las otras once variables no alcanzan significación, con valores p entre 0,227 y 0,992. La prueba de Wilcoxon-Mann-Whitney, alternativa no paramétrica que no requiere normalidad ni varianzas iguales, señala exactamente las mismas siete diferencias significativas.

Que Levene rechace en las discriminantes indica que los grupos no sólo difieren en el valor típico sino también en su dispersión, un hallazgo que se desarrolla en la sección 8. La Figura 2 lo muestra: en triglicéridos, colesterol y sobre todo en índice de masa corporal, las cajas del alto riesgo son más altas y más anchas.

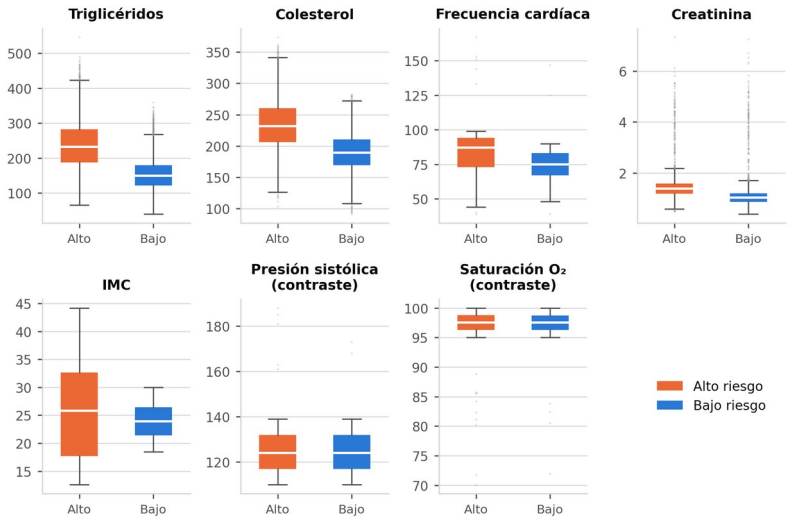


Figura 2. Distribución de las cinco variables discriminantes por grupo de riesgo, con dos variables de contraste. La presión sistólica y la saturación de oxígeno presentan distribuciones superpuestas.

4.2. Lectura clínica de las cinco variables

Triglicéridos (d = 1,411). El alto riesgo promedia 237,95 mg/dL, por encima del umbral de 200 mg/dL a partir del cual se considera elevado; el bajo riesgo, 155,12 mg/dL, apenas sobre el límite de 150. La diferencia no es de grado sino de categoría clínica.

Colesterol total (d = 1,248). 233,80 mg/dL en alto riesgo, cerca del umbral de 240 que define el colesterol alto, frente a 190,03 mg/dL en bajo riesgo, por debajo del valor deseable de 200.

Frecuencia cardíaca (d = 0,798). Es la única variable de signos vitales que discrimina: 83,63 latidos por minuto en alto riesgo y 74,99 en bajo riesgo. Ambos valores están dentro del rango normal, de modo que la diferencia no es una anomalía detectable en un control individual sino un desplazamiento de toda la distribución. Esta variable no forma parte del subconjunto metabólico convencional; excluirla habría dejado fuera una dimensión completa del problema.

Creatinina (d = 0,699). Refleja la función renal: 1,43 mg/dL en alto riesgo, por encima del límite de 1,3, frente a 1,10 mg/dL en bajo riesgo.

Índice de masa corporal (d = 0,290). Las medias son muy próximas —25,84 frente a 24,00—, pero la diferencia relevante de esta variable no está en su centro sino en su dispersión, que se analiza en la sección 8.

5. Las cinco variables en conjunto: visualización multivariada y contraste de medias

La comparación variable por variable deja dos preguntas abiertas: si las cinco variables dicen cosas distintas o se superponen, y cómo se distribuyen los pacientes cuando se las mira a la vez. Esta sección responde con representaciones multivariadas y un contraste formal del vector de medias. Cada gráfico se eligió para responder una pregunta distinta (Tabla 3).

Tabla 3. Representaciones multivariadas utilizadas y pregunta que responde cada una.

Representación	Pregunta que responde	Por qué es la adecuada
Dispersión tridimensional (Fig. 3)	¿Cómo se ubican los pacientes en el espacio de las tres variables del eje principal?	Muestra la nube completa y su solapamiento; permite ver subgrupos que la media esconde.
Coordenadas paralelas (Fig. 4)	¿Cómo se comporta cada paciente en las cinco variables a la vez?	Representa individuos, no promedios, en más de tres dimensiones sin superponer ejes.
Perfiles multivariados (Fig. 5a)	¿En qué variables y por cuánto difieren las medias de los grupos?	Permite leer el valor de cada media y comparar la distancia entre perfiles variable por variable.
Gráfico radial (Fig. 5b)	¿Qué forma tiene el perfil de cada grupo?	Resume en una figura el tamaño y la forma del perfil; facilita ver qué grupo domina en qué eje.
Estrellas y caras de Chernoff (Fig. 13)	¿Qué distingue a los subgrupos dentro del alto riesgo?	Son adecuados para pocos casos: aquí, los centros de cuatro grupos (sección 8.2).

5.1. Dispersión tridimensional

La Figura 3 representa a los pacientes en el espacio de triglicéridos, colesterol e índice de masa corporal, las tres variables que más se correlacionan entre sí y que conforman el primer componente principal (sección 7). Para que la nube sea legible se dibuja uno de cada cuatro pacientes (3.333 puntos); los círculos con borde negro marcan el centro de cada grupo calculado sobre todos los pacientes.

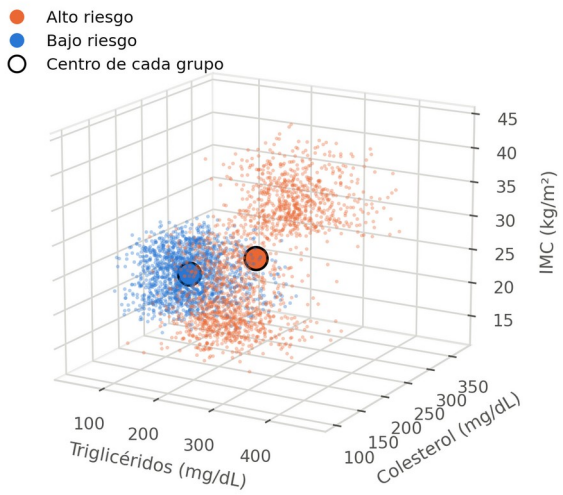


Figura 3. Dispersión tridimensional de triglicéridos, colesterol e índice de masa corporal según la categoría de riesgo (uno de cada cuatro pacientes).

El bajo riesgo forma una nube compacta, con lípidos bajos y un índice de masa corporal intermedio. El alto riesgo está desplazado hacia valores mayores de triglicéridos y colesterol, pero sobre todo aparece partido en dos a lo largo del eje del índice de masa corporal: una parte por encima de 30, con los lípidos más altos de toda la base, y otra por debajo de 18,5. Entre ambas queda una franja de pacientes de alto riesgo con peso normal que se superpone con el bajo riesgo en estas tres variables. El centro del alto riesgo cae en una zona poco poblada: medida la distancia sobre las tres variables estandarizadas, sólo 97 de sus 7.012 pacientes (1,4 %) están a menos de 0,5 de él, contra 616 de los 6.319 de bajo riesgo (9,7 %) respecto del centro propio. Es un primer indicio de que el promedio de ese grupo no describe a un paciente típico.

5.2. Coordenadas paralelas, perfiles multivariados y gráfico radial

En las coordenadas paralelas (Figura 4) cada línea es un paciente y cada eje vertical una variable estandarizada; se dibuja uno de cada diez pacientes (1.334 líneas) y los valores se truncan en ±3 desvíos para que los casos extremos no compriman el gráfico.

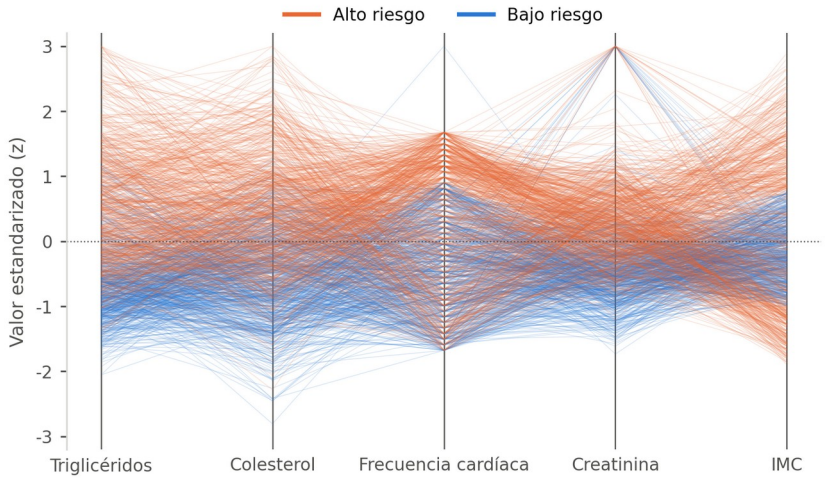


Figura 4. Coordenadas paralelas de las cinco variables discriminantes estandarizadas (uno de cada diez pacientes).

En triglicéridos y colesterol las líneas del alto riesgo recorren la mitad superior de los ejes y las del bajo riesgo la inferior. En frecuencia cardíaca el alto riesgo ocupa casi en exclusiva la franja alta: 3.018 de sus pacientes superan los 90 latidos por minuto, contra sólo 2 del bajo riesgo. En el eje del índice de masa corporal ocurre algo distinto: las líneas del bajo riesgo se concentran en el centro, mientras que las del alto riesgo se abren en abanico hacia los dos extremos. Este comportamiento no se ve en ninguna comparación de medias y es la razón de la baja magnitud de efecto de esa variable.

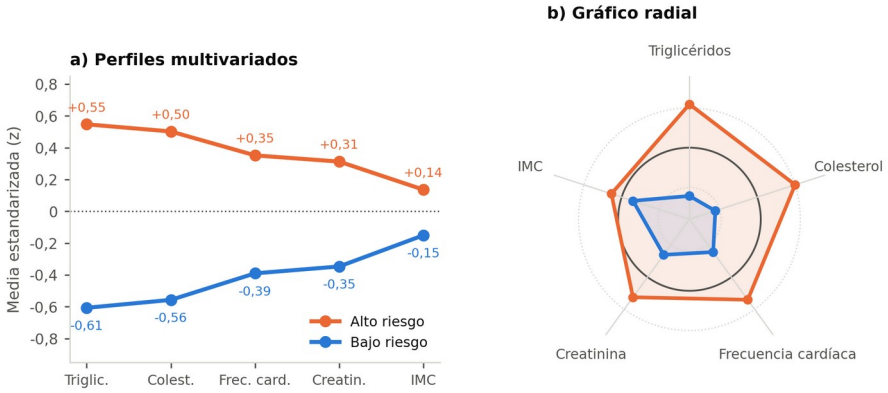


Figura 5. Medias estandarizadas de las cinco variables por grupo de riesgo: a) perfiles multivariados; b) gráfico radial. En b, el círculo negro marca la media de la base completa.

La Figura 5 resume a cada grupo por su perfil de medias estandarizadas. El perfil del alto riesgo está por encima de la media general en las cinco variables (+0,55 en triglicéridos, +0,50 en colesterol, +0,35 en frecuencia cardíaca, +0,31 en creatinina y +0,14 en índice de masa corporal) y el del bajo riesgo por debajo en todas. La distancia entre ambos perfiles disminuye de triglicéridos a índice de masa corporal, donde es de apenas 0,29 desvíos: el mismo orden que la magnitud del efecto. En el gráfico radial el polígono del alto riesgo envuelve al del bajo riesgo en los cinco ejes; los dos polígonos se acercan en el índice de masa corporal, donde la diferencia está en la dispersión y no en la media. Los perfiles permiten leer el valor exacto de cada media; el radial, la forma global del perfil.

5.3. Contraste multivariado de medias

La selección de variables se hizo de a una. Para verificarla en el espacio multivariado se compararon los vectores de medias de los dos grupos con la prueba T^2 de Hotelling para dos muestras independientes, cuya hipótesis nula es que los dos vectores de medias son iguales. El estadístico se construye a partir de la distancia de Mahalanobis entre los centros de los grupos, calculada con la matriz de covarianzas común, que tiene en cuenta las correlaciones entre variables y no cuenta dos veces la información que comparten. Con una sola variable, esa distancia coincide con $|d|$.

Tabla 4. Contraste de igualdad de vectores de medias entre alto y bajo riesgo (T^2 de Hotelling).

Conjunto de variables	D de Mahalanobis	T^2	F	gl	p
5 variables discriminantes	**2,218**	**16.350,0**	**3.269,0**	**5; 13.325**	**< 0,001**
13 variables restantes	0,183	111,9	8,6	13; 13.317	< 0,001

Los dos contrastes resultan significativos, pero la magnitud es muy distinta. Las cinco variables separan los centros de los grupos 2,218 desvíos: más que la mejor variable sola (1,411), aunque menos que la suma, porque triglicéridos, colesterol e índice de masa corporal comparten información. Las trece restantes, todas juntas, apenas los separan 0,183: doce veces menos que las cinco y menos que el índice de masa corporal solo. Su significación es, otra vez, un efecto del tamaño de muestra. Las trece variables descartadas no esconden un efecto conjunto.

La prueba de Hotelling supone normalidad multivariante y matrices de covarianza iguales. La Figura 6 compara las distancias de Mahalanobis al cuadrado con los cuantiles de una chi-cuadrado de 5 grados de libertad, que es lo esperable bajo normalidad. Hasta el percentil 90 los puntos siguen de cerca la recta de referencia (8,16 frente a 9,24 esperado), pero la cola superior se aparta con claridad: el percentil 99 de las distancias es 33,01 cuando se esperaría 15,09. El coeficiente de curtosis multivariante de Mardia confirma la falta de normalidad (65,06, contra 35 esperado). Con más de 6.000 pacientes por grupo, el contraste de medias es robusto a estos apartamientos, y la diferencia de magnitud entre 2,218 y 0,183 es tan grande que la conclusión no depende del supuesto.

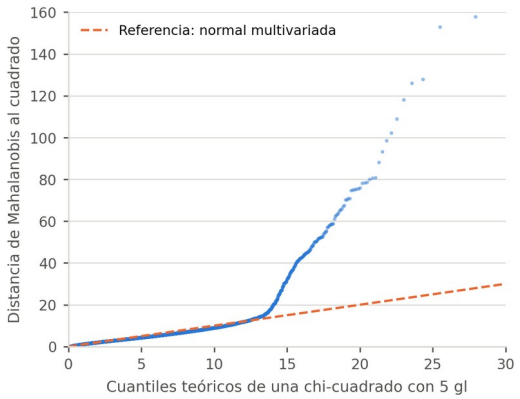


Figura 6. Gráfico Q-Q de las distancias de Mahalanobis al cuadrado frente a una chi-cuadrado de 5 grados de libertad.

6. Qué no separa a los dos grupos de riesgo

Trece de las dieciocho variables cuantitativas no distinguen a un paciente de alto riesgo de uno de bajo riesgo: el conjunto completo de la presión arterial, la temperatura, la saturación de oxígeno, la frecuencia respiratoria, la variabilidad de la frecuencia cardíaca, la hemoglobina, el peso, la altura, la edad y la glucosa. No son variables inútiles: la presión arterial y la saturación son indicadores de primer orden en el manejo individual del paciente. Lo que el análisis muestra es más acotado: en esta población, y para este sistema de clasificación, no contribuyen a diferenciar los niveles de riesgo.

6.1. Variables categóricas: tablas de contingencia

Para cada una de las diez variables categóricas se construyó la tabla de contingencia con la categoría de riesgo y se calcularon sus tres lecturas porcentuales (Tabla 5). El porcentaje sobre el total reparte la base entre las combinaciones de categoría y grupo de riesgo; sumados, los dos valores de una fila dan el peso de esa categoría en la base. El porcentaje por fila es la proporción de alto riesgo dentro de cada categoría: si la variable no se asocia con el riesgo, todas las filas deben estar cerca del 52,60 % global. El porcentaje por columna es la distribución de la variable dentro de cada grupo de riesgo: sin asociación, la columna del alto riesgo y la del bajo riesgo deben ser casi iguales. En actividad física, región y ocupación los porcentajes se calculan sobre los registros con dato.

Tabla 5. Tablas de contingencia de las diez variables categóricas con la categoría de riesgo: porcentajes sobre el total, por fila (proporción de alto riesgo en la categoría) y por columna (distribución de la variable en cada grupo).

Variable	Categoría	n	% total: alto	% total: bajo	% fila: alto	% col.: alto	% col.: bajo
Sexo	Femenino	6.665	26,29	23,70	52,59	49,99	50,01
	Masculino	6.666	26,31	23,70	52,61	50,01	49,99
Diagnóstico	Diabetes	2.487	9,70	8,96	51,99	18,44	18,90
	Enfermedad cardíaca	1.300	5,06	4,69	51,92	9,63	9,89
	EPOC	1.557	6,04	5,64	51,70	11,48	11,90
	Hipertensión	3.289	12,87	11,80	52,17	24,47	24,89
	Sano	4.698	18,93	16,32	53,70	35,98	34,42
Hábito tabáquico	Ex fumador	3.392	13,40	12,05	52,65	25,47	25,42
	Fumador actual	2.600	10,06	9,44	51,58	19,12	19,92
	Nunca	7.339	29,14	25,91	52,94	55,41	54,66
Actividad física	Alta	3.347	15,69	14,95	51,21	29,87	31,49
	Baja	3.835	18,66	16,45	53,14	35,52	34,66
	Media	3.741	18,18	16,07	53,09	34,61	33,85
Región	Rural	3.304	13,76	12,10	53,21	26,16	25,54
	Semiurbana	4.082	16,60	15,35	51,96	31,56	32,40
	Urbana	5.388	22,25	19,93	52,75	42,29	42,06
Nivel socioec.	Alto	2.017	7,96	7,17	52,60	15,13	15,13
	Bajo	5.290	21,30	18,38	53,69	40,50	38,77
	Medio	6.024	23,34	21,85	51,64	44,37	46,10
Ocupación	Estudiante	2.785	11,34	10,26	52,50	21,55	21,64
	Jubilado	3.289	13,49	12,01	52,90	25,65	25,34
	Oficinista	3.657	15,07	13,29	53,13	28,64	28,04
	Trabajo manual	3.166	12,71	11,84	51,77	24,16	24,98
Turno	Mañana	5.460	21,89	19,07	53,44	41,61	40,23
	Noche	3.234	12,47	11,78	51,42	23,72	24,86
	Tarde	4.637	18,24	16,55	52,43	34,67	34,91
Estación	Invierno	3.229	12,96	11,26	53,52	24,64	23,75
	Otoño	3.287	12,95	11,70	52,54	24,63	24,69
	Primavera	3.119	12,30	11,09	52,58	23,39	23,41
	Verano	3.696	14,38	13,34	51,87	27,34	28,15
Grupo etario	18 a 39	4.054	15,78	14,63	51,90	30,01	30,86
	40 a 64	4.671	18,54	16,50	52,90	35,24	34,82
	65 o más	4.606	18,28	16,27	52,91	34,75	34,33

Las tres lecturas coinciden. Por fila, el porcentaje de alto riesgo oscila entre 51,21 % (actividad física alta) y 53,70 % (diagnóstico sano): un rango de apenas 2,49 puntos, y ninguna de las 33 categorías se aparta más de 1,39 puntos del 52,60 % global. Por columna, la distribución de cada variable es prácticamente la misma en ambos grupos: la mayor diferencia es de 1,73 puntos, en el nivel socioeconómico: el nivel bajo reúne el 40,50 % del alto riesgo y el 38,77 % del bajo riesgo, y el nivel medio, el 44,37 % y el 46,10 %. La Figura 7 lo muestra con barras al 100 %: el corte entre ambos colores queda alineado con la línea del 52,60 % en todas las categorías.

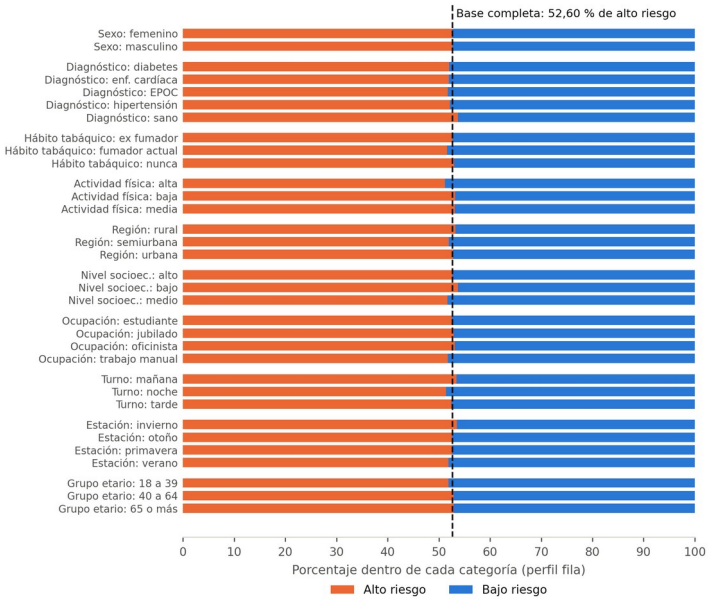


Figura 7. Composición de cada categoría según el grupo de riesgo (barras al 100 %). La línea discontinua marca el 52,60 % de alto riesgo de la base completa.

En esta población no existe gradiente social del riesgo: ni el nivel socioeconómico, ni la región, ni la ocupación modifican la probabilidad de ser clasificado como de alto riesgo. Tampoco los factores conductuales: los fumadores actuales tienen 51,58 % de alto riesgo y quienes nunca fumaron 52,94 %; los pacientes con actividad física alta, 51,21 % frente a 53,14 % con actividad baja, diferencias de signo contrario al esperado y de magnitud despreciable. El sexo arroja 52,61 % en varones y 52,59 % en mujeres, y los pacientes sanos son levemente los más propensos a figurar como de alto riesgo (53,70 %).

Nota metodológica: la prueba chi-cuadrado de independencia y las medidas de asociación para tablas de contingencia corresponden a una unidad posterior del programa; se aplicarán en la segunda fase, junto con el análisis de correspondencias. La lectura presentada aquí es descriptiva.

6.2. El caso de la glucosa: riesgo y diagnóstico son dimensiones distintas

La glucosa es la variable que mejor explica el diagnóstico: el diagnóstico explica el 67,9 % de su variabilidad (cociente $\eta^2 = 0{,}679$; razón de correlación $\eta = 0{,}824$). Los pacientes diabéticos promedian 178,73 mg/dL, muy por encima del umbral diagnóstico de 126, mientras que los otros cuatro grupos rondan los 100 mg/dL: 100,54 en enfermedad pulmonar obstructiva crónica, 100,10 en sanos, 100,04 en enfermedad cardíaca y 99,99 en hipertensión. Y sin embargo es una de las variables que menos separan el riesgo: $d = -0{,}004$, con 114,71 mg/dL en alto riesgo y 114,87 en bajo riesgo.

El diagnóstico y la categoría de riesgo no son dos versiones de una misma idea sino dos dimensiones independientes: un paciente diabético no es, por serlo, de alto riesgo según el sistema vigente. Por eso la glucosa se excluyó del análisis de componentes: con ella, el índice de Kaiser-Meyer-Olkin global baja de 0,672 a 0,562 y el de la propia glucosa es 0,358, por debajo del mínimo de 0,50.

7. Estructura conjunta de las variables discriminantes

7.1. Covarianza y correlación

Las varianzas de las cinco variables difieren en cuatro órdenes de magnitud: 5.155,17 en triglicéridos, 1.708,58 en colesterol, 135,49 en frecuencia cardíaca, 41,15 en índice de masa corporal y 0,25 en creatinina (Tabla 6). La covarianza entre triglicéridos y colesterol es de 1.362,43 y la de creatinina con índice de masa corporal, de 0,16, pero esa diferencia refleja las unidades de medida y no la intensidad de la asociación: expresadas como correlaciones (Tabla 7), valen 0,459 y 0,050. Por eso todo el análisis multivariado se realiza sobre la matriz de correlación.

Tabla 6. Matriz de varianzas y covarianzas de las cinco variables discriminantes. En la diagonal, las varianzas.

	Triglic.	Colest.	Frec. card.	Creatin.	IMC
Triglicéridos	5.155,17	1.362,43	99,36	7,44	186,62
Colesterol	1.362,43	1.708,58	52,41	3,80	104,14
Frecuencia cardíaca	99,36	52,41	135,49	0,70	0,01
Creatinina	7,44	3,80	0,70	0,25	0,16
Índice de masa corporal	186,62	104,14	0,01	0,16	41,15

Tabla 7. Matriz de correlación de las cinco variables discriminantes.

	Triglic.	Colest.	Frec. card.	Creatin.	IMC
Triglicéridos	1,000	0,459	0,119	0,206	0,405
Colesterol	0,459	1,000	0,109	0,183	0,393
Frecuencia cardíaca	0,119	0,109	1,000	0,119	0,000
Creatinina	0,206	0,183	0,119	1,000	0,050
Índice de masa corporal	0,405	0,393	0,000	0,050	1,000

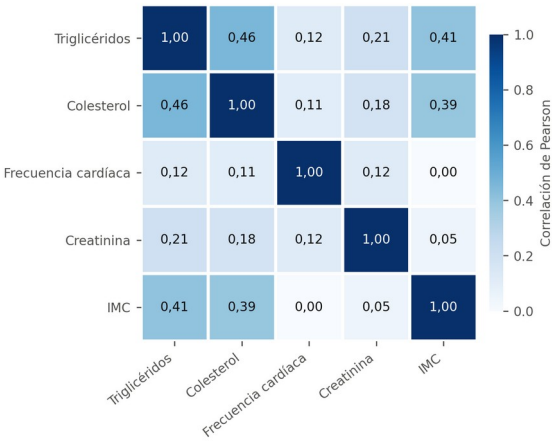


Figura 8. Matriz de correlación de las cinco variables discriminantes.

Las cinco variables forman dos agrupamientos. Triglicéridos, colesterol e índice de masa corporal se correlacionan de manera moderada y consistente (0,459, 0,405 y 0,393). Frecuencia cardíaca y creatinina se mantienen casi independientes de ese bloque, con correlaciones de 0,000 a 0,206. La estructura anticipa la reducción dimensional: no hay un único gradiente de gravedad sino al menos dos fenómenos distintos.

7.2. Observaciones atípicas multivariadas

Sobre las cinco variables estandarizadas se calculó la distancia de Mahalanobis de cada paciente al centro de la nube, que tiene en cuenta las correlaciones y detecta combinaciones anómalas de valores

que, de a uno, son normales. Con el umbral de 4,529 —raíz cuadrada del percentil 99,9 de una chi-cuadrado de 5 grados de libertad— se identificaron 198 observaciones atípicas, con una distancia máxima de 12,56. Se reparten casi por igual: 97 de alto riesgo y 101 de bajo riesgo. Los atípicos multivariados no son, por lo tanto, los pacientes de alto riesgo. Ninguno fue excluido.

7.3. Reducción a componentes principales

La prueba de esfericidad de Bartlett arroja 7.620,4 con 10 grados de libertad ($p < 0{,}001$): se rechaza que la matriz de correlación sea la identidad, es decir, hay correlaciones que aprovechar. El índice de Kaiser-Meyer-Olkin global es 0,672, con valores individuales entre 0,636 (frecuencia cardíaca) y 0,682 (colesterol). El criterio de Kaiser retiene dos componentes, con autovalores de 1,940 y 1,069, que explican el 60,2 % de la varianza (38,8 % y 21,4 %); el gráfico de sedimentación (Figura 9) muestra el codo en el mismo lugar.

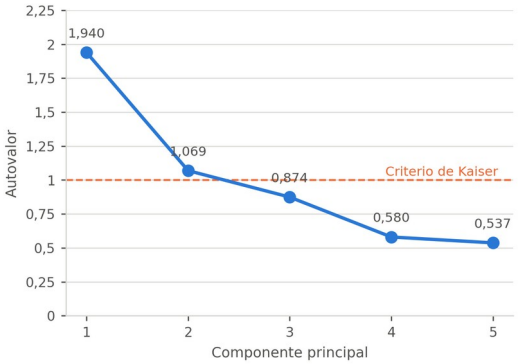


Figura 9. Gráfico de sedimentación. Dos componentes superan el criterio de Kaiser.

Tabla 8. Cargas factoriales de las cinco variables sobre los dos componentes retenidos.

Variable	CP1	CP2	Comunalidad
Triglicéridos	0,797	−0,058	0,639
Colesterol	0,783	−0,087	0,620
Índice de masa corporal	0,692	−0,420	0,655
Frecuencia cardíaca	0,241	0,744	0,613
Creatinina	0,394	0,572	0,483

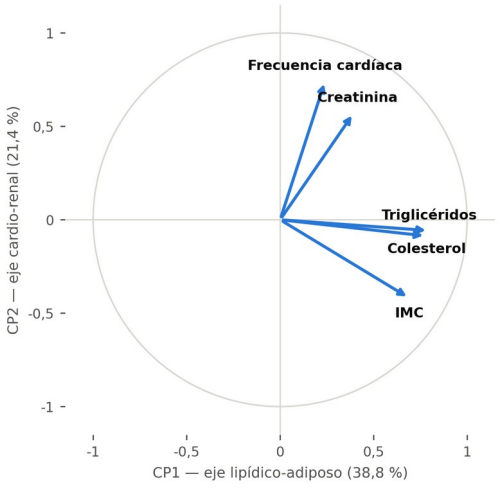


Figura 10. Representación de las cinco variables en el plano de los dos primeros componentes (cargas).

El primer componente es un eje lipídico-adiposo. Concentra las cargas de triglicéridos (0,797), colesterol (0,783) e índice de masa corporal (0,692): mide, en una sola magnitud, la alteración de los

lípidos asociada al exceso de masa corporal. **El segundo es un eje cardio-renal.** Reúne frecuencia cardíaca (0,744) y creatinina (0,572), independiente del anterior; la carga negativa del índice de masa corporal (−0,420) indica que este compromiso aparece más en pacientes con menor masa corporal. Las comunalidades muestran que el plano recoge entre el 48,3 % (creatinina) y el 65,5 % (índice de masa corporal) de cada variable. El tercer componente, con autovalor 0,874, opone frecuencia cardíaca (0,611) a creatinina (−0,694): separa lo cardíaco de lo renal, una distinción real pero de menor peso.

7.4. Los grupos de riesgo en el plano factorial

El análisis de componentes se calculó sin la etiqueta de riesgo, pero las cinco variables fueron elegidas justamente porque separan los grupos. Que los componentes también los separen era, por lo tanto, esperable, y no constituye una validación independiente de la selección; esa evidencia se presenta en el apartado siguiente. Lo que el plano sí aporta es cómo se separan los grupos (Figura 11).

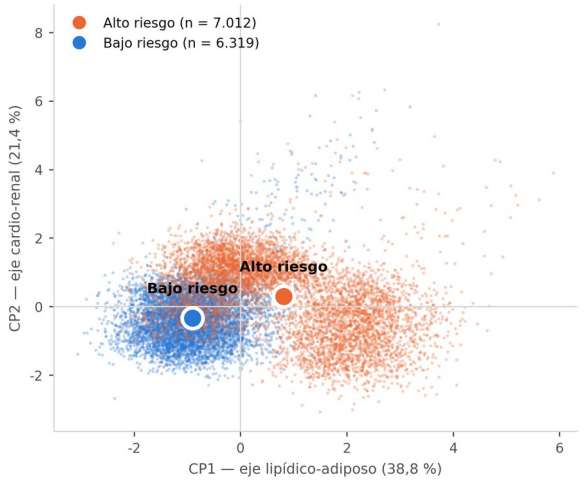


Figura 11. Pacientes en el plano de los dos primeros componentes según su categoría de riesgo. Los puntos con borde blanco marcan el centro de cada grupo.

Sobre el primer componente, el alto riesgo promedia 0,812 y el bajo riesgo −0,901: una magnitud de efecto de 1,558, superior a la de cualquier variable por separado. Sobre el segundo, las medias son 0,298 y −0,331, con una magnitud de 0,638. Ambos ejes separan los grupos, de modo que la clasificación de riesgo integra al menos dos dimensiones independientes. La nube del alto riesgo, además, es mucho más extendida: en el primer componente dispersa 1,98 veces más que la del bajo riesgo.

7.5. Resultado de control: catorce variables sin selección previa

Se repitió el análisis sobre catorce variables cuantitativas, excluyendo sólo peso y altura, que son componentes del cálculo del índice de masa corporal, y la presión arterial media y la presión de pulso, que se calculan a partir de la sistólica y la diastólica. Con las dieciocho, esas relaciones casi exactas producen correlaciones parciales de hasta 0,98 en valor absoluto (presión de pulso con sistólica, índice de masa corporal con peso) y el índice de Kaiser-Meyer-Olkin cae a 0,314. Sobre las catorce, el índice es 0,556 y el criterio de Kaiser retiene siete componentes para explicar apenas el 60,5 % de la varianza, sin un codo identificable: la mayoría de esas variables no se relacionan entre sí. Cinco variables alcanzan una proporción equivalente con sólo dos componentes.

Este análisis aporta además la evidencia que no depende de la selección. Sin que ninguna variable se haya elegido mirando la etiqueta de riesgo, su primer componente vuelve a reunir triglicéridos, colesterol e índice de masa corporal (cargas de 0,842, 0,739 y 0,649 en valor absoluto) y separa los grupos con una magnitud de efecto de 1,469. El eje lipídico-adiposo existe en los datos con independencia del recorte; elegir las cinco variables sólo lo depura.

8. El grupo de alto riesgo no es homogéneo

8.1. Dispersión comparada y distribución del índice de masa corporal

El alto riesgo es más disperso que el bajo riesgo en cuatro de las cinco variables discriminantes: la razón entre desvíos estándar es de 1,35 en triglicéridos, 1,30 en colesterol y 1,36 en frecuencia cardíaca. En creatinina ocurre lo contrario (0,91: 0,45 frente a 0,50). El índice de masa corporal es un caso de otro orden: el desvío del alto riesgo es 2,64 veces el del bajo riesgo (8,24 frente a 3,12), y la prueba de Levene da F = 8.917,1.

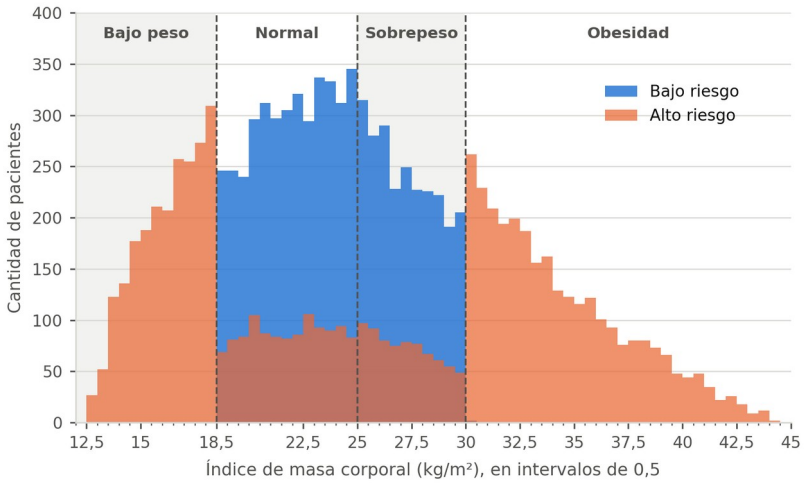


Figura 12. Distribución del índice de masa corporal por grupo de riesgo, en intervalos de 0,5 alineados con los cortes clínicos de 18,5, 25 y 30. Las bandas indican las categorías de bajo peso, normal, sobrepeso y obesidad.

Los 6.319 pacientes de bajo riesgo se concentran en el intervalo [18,50; 30,00]: 3.884 en rango normal, 2.433 en sobrepeso y apenas 2 en el límite exacto que separa el sobrepeso de la obesidad. El grupo de alto riesgo, en cambio, se extiende de 12,59 a 44,19 y presenta dos modas separadas: 2.215 pacientes con bajo peso (índice inferior a 18,50) y 2.921 con obesidad (índice igual o superior a 30,00), más 1.876 pacientes en el rango normal o de sobrepeso (1.144 y 732). En conjunto, el 73,2 % del alto riesgo queda fuera del intervalo [18,5; 30], y ningún paciente de bajo riesgo. Si en lugar del valor se compara la distancia de cada paciente a la mediana de la base (24,31), la magnitud del efecto del índice de masa corporal sube de 0,290 a 1,579, a la par de los triglicéridos.

El riesgo, medido sobre el índice de masa corporal, no describe un gradiente sino una relación en forma de U: tanto el déficit como el exceso de masa corporal conducen a la misma etiqueta. Al promediar ambos extremos, las desviaciones se compensan y la media del alto riesgo se aproxima artificialmente a la del bajo riesgo.

8.2. Tres perfiles bajo una misma etiqueta

Para describir esa heterogeneidad se dividió al alto riesgo en tres subgrupos según los cortes clínicos del índice de masa corporal: bajo peso (menos de 18,5), entre 18,5 y 30, y obesidad (30 o más). La Figura 13 representa el centro de cada subgrupo y el del bajo riesgo con diagramas de estrellas y caras de Chernoff, dos representaciones pensadas para comparar pocos casos: en ambas, cada variable se reescala entre el mínimo y el máximo de los cuatro centros. En las estrellas, cada radio es una variable; en las caras, triglicéridos determinan el alto de la cara, el índice de masa corporal su ancho, el colesterol su forma, la creatinina la altura de la boca y la frecuencia cardíaca su ancho.

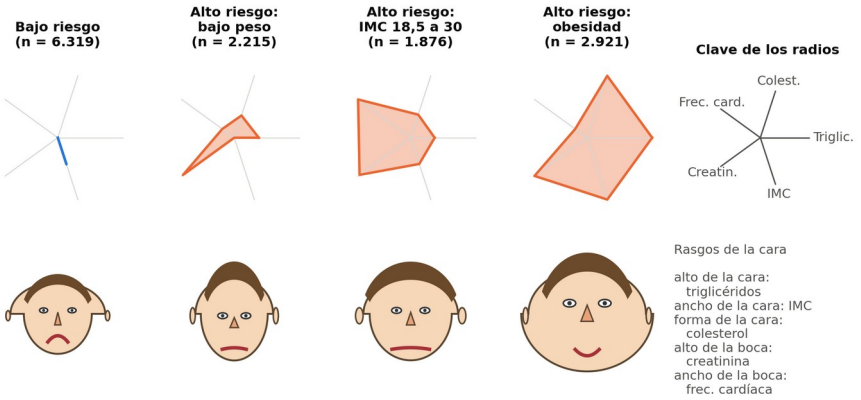


Figura 13. Diagramas de estrellas (arriba) y caras de Chernoff (abajo) del centro del bajo riesgo y de los tres subgrupos del alto riesgo.

Tabla 9. Medias de las cinco variables en el bajo riesgo y en los tres subgrupos del alto riesgo, y prueba de Kruskal-Wallis entre los tres subgrupos.

Variable	Bajo riesgo	Alto: bajo peso	Alto: IMC 18,5 a 30	Alto: obesidad	H	p
Pacientes	6.319	2.215	1.876	2.921		
Triglicéridos	155,12	204,35	203,22	285,74	2.802,2	< 0,001
Colesterol	190,03	214,97	215,95	259,55	2.215,2	< 0,001
Frecuencia cardíaca	74,99	79,52	94,88	79,51	2.446,5	< 0,001
Creatinina	1,10	1,43	1,43	1,44	0,8	0,68
Índice de masa corporal	24,00	16,26	23,93	34,32	—	—

Las figuras muestran tres formas distintas. La estrella del bajo riesgo casi desaparece: es el centro con los valores más bajos en cuatro de las cinco variables. El subgrupo de bajo peso se define por su índice de masa corporal mínimo, con lípidos intermedios. El de índice entre 18,5 y 30 se distingue por la frecuencia cardíaca: 94,88 latidos por minuto, con un desvío de apenas 4,10. El de obesidad combina el índice más alto con los lípidos más elevados de toda la base (triglicéridos de 285,74 mg/dL); su cara es la más alta y la más ancha.

Para contrastar si los subgrupos difieren en las variables que no se usaron para definirlos se aplicó la prueba de Kruskal-Wallis, porque la prueba de Levene rechaza la igualdad de varianzas entre ellos en frecuencia cardíaca, triglicéridos y colesterol. Los tres subgrupos difieren en esas tres variables ($p < 0,001$), pero no en creatinina ($H = 0,8$; $p = 0,68$): la creatinina elevada, de 1,43 a 1,44 mg/dL frente a 1,10 en el bajo riesgo, es lo que los tres comparten.

Hipótesis para la segunda fase. La categoría de alto riesgo no identifica una población homogénea con distintos grados de gravedad, sino que agrupa perfiles clínicamente diferenciados: uno de bajo peso, uno de obesidad con alteración lipídica y uno de compromiso cardíaco con peso normal, unidos por una función renal alterada. Los subgrupos de este informe se definieron con cortes clínicos; la segunda fase deberá contrastar si un agrupamiento no supervisado sobre los componentes principales los reencuentra. De confirmarse, un indicador que reúne pacientes no comparables resulta poco informativo para orientar conductas, y convendría descomponerlo.

9. Conclusiones y líneas de trabajo futuras

9.1. Un núcleo de cinco variables

La distinción entre pacientes de alto y bajo riesgo en el Hospital 4 descansa sobre cinco variables: triglicéridos, colesterol, frecuencia cardíaca, creatinina e índice de masa corporal. La selección resiste cambios de umbral, no depende de suponer varianzas iguales y se confirma en el espacio multivariado.

Las trece variables cuantitativas restantes y las diez categóricas no aportan a esa distinción. Las cinco se organizan en dos dimensiones independientes —un eje lipídico-adiposo y un eje cardio-renal—, y el primero aparece incluso sin seleccionar variables.

Para la institución, si el propósito del panel de control es sostener la clasificación de riesgo, cinco determinaciones cumplen esa función. No es una recomendación de discontinuar variables de valor asistencial indiscutible, como la presión arterial o la saturación, sino una indicación de que su rendimiento para este propósito específico es nulo.

Tabla 10. Síntesis de los principales resultados del informe.

Pregunta	Resultado
¿Cuántas variables cuantitativas separan los grupos?	5 de 18: triglicéridos, colesterol, frecuencia cardíaca, creatinina e IMC
¿Cuál separa más? ¿Cuál no separa?	Triglicéridos (d = 1,411); presión sistólica (d = 0,000)
¿Separan en conjunto?	Sí: D = 2,218 contra 0,183 de las otras trece; Hotelling F(5; 13.325) = 3.269, p < 0,001
¿Alguna variable categórica se asocia al riesgo?	Ninguna: 51,21 % a 53,70 % de alto riesgo en las 33 categorías
¿La glucosa discrimina el riesgo?	No (d = −0,004), aunque sí el diagnóstico (η^2 = 0,679)
¿Cuántas dimensiones contienen las cinco?	2 componentes, 60,2 % de la varianza: lipídico-adiposo (38,8 %) y cardio-renal (21,4 %)
¿Aparece el eje sin seleccionar variables?	Sí: CP1 de catorce variables, |d| = 1,469
¿Es homogéneo el grupo de alto riesgo?	No: dispersa 2,64 veces más en IMC, dos modas y tres perfiles
¿Qué comparten los tres perfiles?	Creatinina de 1,43 a 1,44 mg/dL, sin diferencias entre ellos (p = 0,68)
¿Cuántos atípicos multivariados hay?	198 (97 de alto riesgo y 101 de bajo riesgo)

9.2. Limitaciones del análisis

La magnitud de efecto del índice de masa corporal es baja (0,290). Su inclusión se sostiene porque su diferencia está en la forma de la distribución, no en la media: medida como distancia al centro, su magnitud es 1,579. Una lectura basada sólo en medias la habría descartado. **El índice de Kaiser-Meyer-Olkin es mediocre** (0,672), por encima del mínimo de 0,50; es coherente con el hallazgo, porque el índice penaliza la presencia de bloques poco relacionados, que es lo que muestran los dos componentes. **La varianza explicada es moderada:** el plano recoge el 60,2 % de la variabilidad. **Los supuestos de la prueba de Hotelling no se cumplen estrictamente:** no hay normalidad multivariante ni varianzas iguales, aunque el tamaño de los grupos hace robusto el contraste. **Los subgrupos del alto riesgo se definieron con cortes clínicos** y no por agrupamiento, por lo que constituyen una hipótesis y no un resultado.

9.3. Líneas de trabajo futuras

Tipología de pacientes de alto riesgo: contrastar con técnicas de agrupamiento no supervisado, sobre las puntuaciones de los componentes ya calculadas, si los tres perfiles se reencuentran. **Variables categóricas:** aplicar la prueba chi-cuadrado y el análisis de correspondencias a las tablas de contingencia, incluida la asociación entre diagnóstico y hábito tabáquico, de intensidad llamativa en una exploración preliminar. **Factores latentes:** el análisis factorial exploratorio permitiría evaluar si los dos ejes corresponden a factores con interpretación clínica sustantiva.

9.4. Recomendaciones para el registro de datos

El proceso de depuración puso en evidencia tres problemas del sistema de registro. Primero, el almacenamiento de códigos de error en los mismos campos que los datos válidos, que afectó a 1.452 valores de sexo, categoría de riesgo y marca temporal; convendría registrarlos en un campo separado. Segundo, la ausencia de validación en la carga de las variables categóricas, que permitió escribir una misma categoría de hasta cinco maneras; una lista desplegable lo eliminaría en su origen. Tercero, la

proporción de datos faltantes en las variables de contexto, que alcanza el 30,68 % en el tipo de medicación: no compromete este análisis, pero una variable ausente en casi un tercio de los registros difícilmente sostenga conclusiones futuras.

Anexo. Ficha técnica de la base analizada

Tabla 11. Ficha técnica de la base depurada.

Concepto	Valor
Registros y variables en la base original	15.345 y 34
Columnas eliminadas por falta de contenido	3
Duplicados exactos en el archivo original / eliminados	10 / 9
Códigos de error convertidos a dato faltante	1.452
Registros descartados por siete o más campos ausentes	2.002
Registros descartados por frecuencia cardíaca desconocida	2
Registros descartados por falta de identificación y etiqueta clínica	1
Registros y pacientes en la base final	13.331
Variables en la base final	31 + 5 derivadas
Variables cuantitativas y categóricas analizadas	18 y 10
Pacientes de alto / bajo riesgo	7.012 (52,60 %) / 6.319 (47,40 %)
Faltantes: medicación / actividad física / región / ocupación	30,68 % / 18,06 % / 4,18 % / 3,26 %
Faltantes en variables clínicas	0,00 %

Subconjunto discriminante: triglicéridos, colesterol, frecuencia cardíaca, creatinina e índice de masa corporal. Subconjunto de control del análisis de componentes: catorce variables, sin peso, altura, presión arterial media ni presión de pulso. Todos los análisis multivariados se realizaron sobre variables estandarizadas, con los 13.331 registros completos en las variables cuantitativas.